

Аналитический отчёт по курсовой работе.

Задача: Прогнозирование биологической активности и селективности химических соединений с использованием методов классического машинного обучения.

1. Введение и постановка задач

Целью данной работы является разработка и сравнение моделей машинного обучения для предсказания ключевых характеристик потенциальных лекарственных препаратов. Работа включает анализ 1000 химических соединений, описанных набором молекулярных дескрипторов.

Задачи исследования:

1. Регрессионный анализ: Прогноз количественных значений показателей IC50 (активность), CC50 (цитотоксичность) и SI (индекс селективности).
2. Классификация по медиане: Бинарное разделение соединений на эффективные и малоэффективные относительно медианного значения выборки.
3. Специализированная классификация ($SI > 8$): Идентификация высокоселективных соединений, представляющих наибольший терапевтический интерес.

2. Результаты разведочного анализа данных

В ходе EDA были проведены следующие мероприятия по подготовке данных:

1. Очистка данных: Удален технический столбец и 91 признак с корреляцией 1, для обеспечения стабильности обучения моделей.
2. Анализ распределений: Выявлена сильная асимметрия и наличие выбросов в целевых переменных. Это определило выбор в пользу нелинейных моделей на основе решающих деревьев.
3. Изменение данных: Было проведено логарифмирование признаков для уменьшения влияния выбросов.
4. Отбор признаков: Применен метод mutual information. Для разных задач определены оптимальные наборы признаков ($k=15, 25$ или

50), что позволило сохранить высокую обобщающую способность при снижении сложности моделей.

5. Ограничения для данных: Признак SI вычисляемый, поэтому для моделей были удалены все таргеты чтобы убрать вероятность утечки данных.

3. Блок регрессии

Регрессионный анализ показал что предсказание точных численных значений параметров является сложной задачей из-за высокого уровня экспериментального шума.

Показатель	Лучшая модель	R ²	Ключевой вывод
IC50	Random Forest / CatBoost	0.45 - 0.52	Модель улавливает общие тренды, но чувствительна к экстремальным значениям.
CC50	XGBoost / CatBoost	0.60 - 0.67	Наиболее предсказуемый параметр; дескрипторы хорошо описывают токсичность.
SI (Индекс селективности)	Ансамбли	< 0.30	Низкая точность обусловлена накоплением ошибок при вычислении SI (CC50/IC50).

4. Блок классификации по медиане

Переход к задачам классификации позволил достичь более стабильных и практически значимых результатов.

Задача	Лучшая модель	Accuracy	F1-score	Оптимальное k
IC50_median	CatBoost	0.72	0.72	15
CC50_median	XGBoost	0.77	0.77	50
SI_median	Random Forest	0.71	0.71	25

5. Поиск высокоселективных соединений (SI > 8)

Данная задача наиболее приближена к реальным потребностям фармацевтики — поиску соединений с широким терапевтическим окном.

- **Лидеры:** XGBoost и CatBoost показали accuracy 0.75.
- **Метрики:** Высокий precision 0.76 при невысоком recall 0.43. В контексте исследования лекарств это оправдано: лучше найти меньше соединений, но быть уверенным в их качестве, чтобы не тратить бюджет на синтез бесперспективных веществ.

6. Общие выводы и рекомендации

1. **Эффективность алгоритмов:** Градиентный бустинг (XGBoost, CatBoost) продемонстрировал превосходство над классическими методами, эффективно работая с компактным набором из 15 дескрипторов.
2. **Оценка методологии:** Классификация является более надежным инструментом для первичного скрининга библиотек соединений, чем прямая регрессия индекса селективности.
3. **Рекомендации по развитию:** Использование методов балансировки классов (SMOTE или веса) для улучшения поиска редких селективных соединений. Создание стекинга (Stacking) из топ-моделей для стабилизации предсказаний. Кросс-анализ топ признаков моделей для отбора самых важных предикторов. Расширение датасета и консультация эксперта для понимания предметной области.